

Optimización Numérica: Laboratorio 3

rodrigo.mendoza@itam.mx

24 Septiembre 2019

1 Programación Cuadrática

Supongamos que tenemos un conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, y_i) \in \mathbb{R}^p \times \{-1, 1\} : i \in [m]\}$. Se dice que los puntos son *linealmente separables* si existe un hiperplano $\mathbf{w}^T \mathbf{x} + b = 0$ tal que $\mathbf{w}^T \mathbf{x}_i + b > 0$ si $y_i > 0$ y $\mathbf{w}^T \mathbf{x}_i + b < 0$ si $y_i < 0$ $\forall i \in [m]$. Queremos encontrar el hiperplano (\mathbf{w}, b) que mejor separe los datos. Una *máquina de soporte vectorial* encuentra el hiperplano que maximiza el *margen*, es decir, la distancia mínima entre el hiperplano y un punto en \mathcal{D} .

1. Demuestre que $\min_{\mathbf{v}} \{\|\mathbf{x} - \mathbf{v}\| : \mathbf{w}^T \mathbf{v} + b = 0\} = |\mathbf{w}^T \mathbf{x} + b|$
Pista: Demuestre que $\mathbf{v} = \mathbf{x} - (\mathbf{w}^T \mathbf{x} + b)\mathbf{w}$ está en el hiperplano y que $\|\mathbf{x} - \mathbf{u}\|^2 \geq \|\mathbf{x} - \mathbf{v}\|^2$ para todo \mathbf{u} en el hiperplano.

2. El modelo *duro* de *máquinas de soporte vectorial* puede formularse como:

$$\arg \max_{(\mathbf{w}, b): \|\mathbf{w}\|=1} \min_{i \in [m]} |\mathbf{w}^T \mathbf{x}_i + b| \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0 \quad \forall i \in [m]. \quad (1)$$

Demuestre que este modelo puede reescribirse como:

$$\arg \max_{(\mathbf{w}, b): \|\mathbf{w}\|=1} \min_{i \in [m]} y_i(\mathbf{w}^T \mathbf{x}_i + b). \quad (2)$$

3. Use este resultado para demostrar que el puede resolverse con

$$(\mathbf{w}_0, b_0) = \arg \max_{(\mathbf{w}, b)} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i \in [m] \quad (3)$$

$$\hat{\mathbf{w}} = \mathbf{w}_0 / \|\mathbf{w}_0\|$$

$$\hat{b} = b_0 / \|\mathbf{w}_0\|$$

Pista: Suponga que (\mathbf{x}^*, b^*) es una solución de (2) y considere $\gamma^* = \min_{i \in [m]} y_i((\mathbf{w}^*)^T \mathbf{x}_i + b^*)$. Demuestre que $\mathbf{w}_0 \leq 1/\gamma^*$ y use esto para demostrar que $(\hat{\mathbf{w}}, \hat{b})$ es óptimo.

4. Un *programa cuadrático* tiene la forma:

$$\begin{aligned} \min_{\mathbf{x}} \quad & \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned} \quad (4)$$

5. Reescriba (3) como un programa cuadrático.

6. Implemente la función `hard_svm` en Python que resuelva (1) usando el método `cvxopt.solvers.qp` (<https://cvxopt.org/userguide/coneprog.html#quadratic-programming>)¹.

```
def hard_svm(X, y):  
    '''(X,y): Datos de entrenamiento [X.shape=(m,p), y.shape=(m,)]  
           X,y matrices de numpy  
           (w,b): Hiperplano [w.shape=(p,), b.shape=(1,)]  
    ...  
    return w, b
```

¹Si lo necesita, puede encontrar un tutorial aquí <https://courses.csail.mit.edu/6.867/wiki/images/a/a7/Qp-cvxopt.pdf>

7. Implemente la siguiente función para generar un conjunto de datos linealmente separables:

```
import numpy as np
def datos(N):
    np.random.seed(1111)
    n = int(N/2)
    cov = [[1, 0], [0, 1]]
    X1 = np.random.multivariate_normal([-9,10], cov, n)
    X2 = np.random.multivariate_normal([7,-8], cov, n)
    X = np.concatenate((X1, X2), axis=0)
    y = np.concatenate((np.ones(n), -1*np.ones(n)), axis=0)
    return X, y.squeeze()
```

8. Pruebe su función `hard_svm` con `(X,y) = datos(200)`. Grafique los puntos con el hiperplano que encontró.